

Predicción de riesgo de incendios forestales en Paraguay: Un enfoque basado en stacking de modelos de Machine Learning con datos geoespaciales

Alexis Rodrigo Arce Delgadillo, María Laura Capdevila Castro,
Gustavo Sosa-Cabrera

Facultad Politécnica - Universidad Nacional de Asunción
Asunción, Paraguay
{alexisroarce2000,lauri.capdevila16}@fpuna.edu.py, gdsosa@pol.edu.py
<http://www.pol.una.py>

Resumen Los incendios forestales constituyen una amenaza creciente a nivel mundial, con impactos significativos sobre los ecosistemas, la economía y la seguridad de la población. Paraguay también se ve afectado por esta problemática, registrando una tendencia creciente en la frecuencia e intensidad de los incendios en los últimos años. Este estudio propone un modelo predictivo de riesgo de incendios forestales en Paraguay, utilizando un enfoque de Machine Learning que integra datos satelitales, topográficos y meteorológicos. Se desarrolló un modelo de ensamble tipo stacking, que combina algoritmos como Random Forest, Support Vector Machines (SVM) y K-Nearest Neighbors (KNN), con una regresión logística como meta-modelo para clasificar la probabilidad de ocurrencia de incendios. Los resultados preliminares evidencian la viabilidad del modelo para generar mapas de riesgo espacialmente explícitos, ofreciendo una herramienta potencial para la gestión proactiva de desastres.

Palabras Claves: Incendios Forestales · Machine Learning · Análisis Geoespacial · Modelos Predictivos · Modelo de Stacking · Predicción de Riesgo · Paraguay

1. Introducción

Los incendios forestales constituyen una problemática ambiental de escala global. Paraguay, conocido por su riqueza ecológica y productiva, se ve cada vez más amenazado por los incendios forestales, fenómeno agravado por el cambio climático y la intervención antrópica. En este contexto, anticipar incendios en tiempo y espacio es esencial para proteger el ambiente y la población. Los métodos tradicionales, basados en enfoques estáticos y experiencia local, no capturan la complejidad ni la dinámica del problema. En la actualidad, el acceso a grandes volúmenes de datos geoespaciales, junto con los avances en técnicas de análisis computacional como el aprendizaje automático, permiten el desarrollo de modelos predictivos más precisos. A nivel nacional, estudios recientes han demostrado

que la pérdida de cobertura forestal y cambio de uso del suelo es una de las principales causas de la propagación de incendios forestales en Paraguay, donde se registraron eventos de gran magnitud en 2020 [1]. El presente estudio propone y evalúa un enfoque metodológico basado en Machine Learning, con el objetivo de generar mapas de riesgo de incendios forestales. En el contexto de este estudio, se propone desarrollar un modelo predictivo de incendios forestales en Paraguay, mediante un enfoque de Machine Learning basado en un modelo de ensamble tipo *stacking*, que integra variables meteorológicas, topográficas, antropogénicas, de uso del suelo y de cobertura vegetal para mejorar la clasificación del riesgo.

2. Trabajos Relacionados

Se estableció el estado del arte a partir de una revisión bibliográfica de 80 artículos científicos y trabajos académicos sobre predicción de incendios forestales con Machine Learning. De esta revisión, dos trabajos resultaron fundamentales. A nivel local, la tesis de Fleitas Sosa [1] fue clave para contextualizar el problema en Paraguay y guiar la selección de variables, sentando las bases de este estudio a pesar de no emplear aprendizaje automático. En el plano metodológico, se tomó como referencia principal el trabajo de Baeza Ruiz-Henestrosa [2], quien desarrolló modelos predictivos para incendios en España. Si bien este estudio comparte el uso de variables similares (meteorológicas, topográficas, etc.), nuestro principal aporte y diferenciación radica en la implementación de un modelo de ensamble de tipo *stacking*. Esta técnica combina múltiples algoritmos base para crear un meta-modelo más robusto y preciso, mejorando la capacidad predictiva en un problema de clasificación complejo como este.

3. Materiales y Métodos

3.1. Pipeline

1. **Data.** Se generó un conjunto de datos geoespaciales para el área de estudio, compuesto por muestras positivas y negativas a partir de las observaciones de focos de calor del sistema FIRMS¹ de la NASA. Las muestras negativas se obtuvieron seleccionando puntos dentro de una máscara de zonas potencialmente inflamables, construida a partir de la cobertura del suelo². Esta estrategia permitió focalizar el análisis en zonas inflamables, diferenciando entre áreas con y sin incendios, y evitando sesgos derivados del tipo de uso del suelo.

Se seleccionaron 11 variables predictoras basadas en factores críticos para la ocurrencia de incendios. Estudios como Moghim y Mehrabi [3] han validado la eficacia de variables similares, incluyendo cobertura del suelo, NDVI, y factores topográficos y meteorológicos. Estas variables se agrupan de la siguiente manera:

¹ <https://firms.modaps.eosdis.nasa.gov>

² <https://mapbiomas.org/paraguay>

Topográficas. Se utilizó el Modelo Digital de Elevación (DEM) NASADEM con resolución de 30 m, accedido a través de Google Earth Engine.³

Vegetación. Se procesaron compuestos mensuales de NDVI a partir del producto MODIS MOD13A1 v061, accedido vía Google Earth Engine.⁴

Cobertura del suelo. Se utilizaron datos de cobertura y uso del suelo de la Colección 2 de MapBiomias Paraguay, accedidos mediante Google Earth Engine.⁵

Meteorológicas. Se extrajeron series diarias de temperatura, precipitación, viento y humedad relativa del modelo ERA5-Land, utilizando **Google Earth Engine** para su procesamiento eficiente [4].

Antropogénicas. Se calcularon variables de proximidad euclidiana a elementos clave, como la distancia a vías principales y a centros urbanos, utilizando la cartografía oficial del Instituto Nacional de Estadística (INE) de Paraguay (2022) ⁶

2. **Modelado:** Se implementó un clasificador de ensamble tipo *Stacking*.
 - **Modelos Base (Nivel 0):** RandomForestClassifier, Support Vector Machine CalibratedClassifierCV con LinearSVC y KNeighborsClassifier.
 - **Meta-Modelo (Nivel 1):** Una *LogisticRegression* que integra las predicciones de los modelos base para emitir la clasificación final.
3. **Validación:** Se implementó una partición por **bloque espacial** dividiendo los datos geográficamente en lugar de hacerlo al azar. El área de estudio fue dividida por **latitud**, utilizando el 50 % de la zona sur para entrenamiento y el 50 % de la zona norte para prueba (Figura 1).

3.2. Resultados Preliminares

El modelo de *Stacking* final alcanzó una **exactitud general (accuracy) del 86.29 %** en el conjunto de prueba. El **AUC fue de 0.94** (Figura 2), lo que demuestra una excelente capacidad del modelo para discriminar entre las clases de Incendio y No Incendio.

El modelo mostró un rendimiento equilibrado, con un **recall del 91 %** y una **precisión del 87 %** para la clase Incendio, y un **recall del 80 %** y **precisión del 85 %** para No Incendio. Los F1-scores fueron de **0.89** y **0.82**, respectivamente, lo que respalda su utilidad para aplicaciones operativas de alerta temprana.

³ NASA JPL. NASADEM Digital Elevation 30m, Version 1. NASA EOSDIS Land Processes DAAC. Disponible en: https://developers.google.com/earth-engine/datasets/catalog/NASA_NASADEM_HGT

⁴ NASA LP DAAC. MODIS/Terra Vegetation Indices 16-Day Global 500m (MOD13A1), Version 6.1. NASA EOSDIS Land Processes DAAC. Disponible en: https://developers.google.com/earth-engine/datasets/catalog/MODIS_061_MOD13A1

⁵ MapBiomias Paraguay. Colección 2 – Cobertura y uso del suelo (2000–2023), v1. Disponible en: <https://mapbiomas.org/paraguay>

⁶ <https://www.ine.gov.py/microdatos/cartografia-digital-2022.php>




Figura 1. Visualización de la partición espacial del conjunto de datos. El área de entrenamiento (azul) y el área de prueba (naranja) están geográficamente separadas, asegurando una evaluación robusta del modelo.




Figura 2. Resultados del Modelo de Stacking. Izquierda: Matriz de Confusión. Derecha: Curva ROC con un AUC de 0.94.

3.3. Generación de Mapa de Riesgo

A partir del modelo entrenado, se construyó un mapa de riesgo para el **15 de agosto de 2023**, aplicando el clasificador sobre una rejilla densa de puntos de predicción en el Departamento de Cordillera. El mapa revela zonas de alto riesgo en el norte y centro del departamento, asociadas a baja humedad, vegetación seca y lejanía de centros urbanos. Estas áreas destacan como prioritarias para vigilancia y gestión.




Figura 3. Mapa de Riesgo de Incendio para el Departamento de Cordillera generado para el 15-08-2023.

4. Líneas de acciones futura

Como trabajo futuro, se plantea avanzar en la incorporación de nuevas variables ambientales y geoespaciales. De esta manera, se espera desarrollar un modelo de predicción más robusto y con mayor capacidad de generalización. Este modelo podría ser aplicado en otros departamentos del país, y servir de base para la creación de herramientas de apoyo a la toma de decisiones en la gestión del riesgo de incendios forestales.

Referencias

1. Fleitas Sosa, D.A.: *Evaluación de la probabilidad de ocurrencia de incendios forestales en el Departamento de Cordillera, Paraguay*. Tesis de Grado, Universidad Nacional de Asunción, Paraguay (2023)
2. Baeza Ruiz-Henestrosa, J.: *Modelos de predicción de incendios forestales*. Trabajo Fin de Grado, Universidad de Sevilla, España (2024).
3. Moghim, S., Mehrabi, M.: Wildfire assessment using machine learning algorithms in different regions. *Fire Ecology* 20(1), 1–20 (2024)
4. Küçükarslan, A.B.: An overview of machine learning (ML) techniques applied to forest fire studies. *Eurasian Journal of Forest Science*, **12**(1), 1–9 (2024).